

HỆ THỐNG CHẤM ĐIỂM CHẤT LƯỢNG DỮ LIỆU DQ SCORING

Mentor: *Đỗ Viết Cường - VAI cuongdv3@gmail.com*

Học viên: *Nguyễn Hoàng Tùng nhtung2705@gmail.com*

Đường dẫn Github: <https://github.com/TheFatGreyCat/dq-scoring/>

1. GIỚI THIỆU CHUNG

1.1. Bối cảnh và nhu cầu thực tiễn

Dữ liệu được thu thập từ nhiều nguồn, có cấu trúc khác nhau và thường xuyên thay đổi. Các lỗi như thiếu trường bắt buộc, sai định dạng, trùng khóa, vi phạm logic nghiệp vụ hoặc dữ liệu không còn kịp thời có thể làm sai lệch kết quả phân tích và giảm độ tin cậy của dataset.

Vì vậy, cần có một hệ thống tự động kiểm tra, đo lường và giải thích chất lượng dữ liệu trước khi dataset được khai thác, chia sẻ hoặc công bố trên sàn giao dịch dữ liệu.

1.2. Mục tiêu và vấn đề giải quyết

Đề tài xây dựng hệ thống DQ Scoring V2 nhằm quản lý dataset theo phiên bản, thực hiện profiling và semantic detection, đề xuất và binding rule, kiểm tra dữ liệu bằng Great Expectations/Python, sau đó tính điểm theo sáu chiều: Completeness, Validity, Uniqueness, Consistency, Timeliness và Accuracy Proxy.

1.3. Vai trò và đóng góp của sinh viên

Sinh viên trực tiếp phân tích yêu cầu, thiết kế kiến trúc và triển khai các module cốt lõi gồm DqRuntime, PostgreSQL repository, profiling, semantic detection, Rule Catalog, recommendation, canonical validation, Scoring V2, Quality Gate, Streamlit Dashboard, CLI và bộ kiểm thử.


Đóng góp trọng tâm là xây dựng pipeline thống nhất từ CSV đến điểm chất lượng; tách Rule Template dùng chung khỏi Dataset Rule Binding; chuẩn hóa kết quả GX/Python; đồng thời thiết kế điểm số có thể truy vết từ dataset xuống dimension, rule và measurement.

2. NỘI DUNG VÀ PHƯƠNG PHÁP THỰC HIỆN

2.1. Kiến trúc và quy trình triển khai


Hệ thống được tổ chức theo kiến trúc nhiều lớp. Streamlit Dashboard và CLI cùng gọi DqRuntime/Orchestration để sử dụng một luồng nghiệp vụ thống nhất. Runtime điều phối các bước onboarding, profiling, semantic detection, recommendation, binding, validation, scoring và ghi pipeline log.

PostgreSQL là nguồn lưu trữ trạng thái tập trung cho metadata, dataset version, profile, rule, measurement, score và log. Repository đồng thời lưu file CSV theo từng phiên bản tại `data/uploads/<dataset_id>/<dataset_version_id>.csv`; schema được quản lý bằng bảng `migration` và được khởi tạo Rule Catalog cùng chính sách SP-default sau khi migrate.



Hình 2.1. Kiến trúc module hệ thống DQ Scoring

Luồng xử lý End-to-end



Hình 2.2. Luồng xử lý end-to-end của hệ thống

2.2. Công nghệ sử dụng

Nhóm	Công nghệ	Vai trò
Xử lý dữ liệu	Python 3.14, pandas	Đọc CSV, profiling, sampling/chunking, semantic detection.
Validation	Great Expectations, Python	Thực thi rule chuẩn, rule nghiệp vụ và chuẩn hóa measurement.
Lưu trữ	PostgreSQL 16, psycopg	Lưu metadata, version, rules, measurements, scores và logs.
Giao diện	Streamlit, CLI	Onboarding, vận hành pipeline và xem kết quả.
Triển khai	Docker Compose	Khởi tạo PostgreSQL local và môi trường demo.
Kiểm thử	pytest, GitHub	Unit, integration, fresh-install smoke và

	Actions	regression test.
--	---------	------------------

2.3. Các cải tiến và ý tưởng đề xuất

- Central Rule Catalog và Dataset Rule Binding: tách quy tắc dùng chung khỏi target, threshold và tham số riêng của từng dataset version, giúp tái sử dụng và quản trị rule tập trung.
- Recommendation có căn cứ: chấm điểm ứng viên theo name, type, semantic, profile, role và catalog priority; hỗ trợ review thủ công hoặc auto-bind với các rule an toàn, đủ độ tin cậy.
- Canonical Measurement Contract: chuyển kết quả Great Expectations và Python về cùng mô hình measured/not_measured, passed, failed, missing và not applicable trước khi scoring.
- Scoring V2 có khả năng giải thích: kết hợp pass ratio, severity, field criticality, conflict group, coverage và policy snapshot; trạng thái chưa đo không bị quy đổi mặc định thành 0 điểm.
- Vận hành có kiểm soát: lưu CSV theo phiên bản, System Health kiểm tra database/schema/catalog/storage và GitHub Actions chạy migration, bootstrap và toàn bộ pytest trên PostgreSQL 16.

3. KẾT QUẢ THỰC HIỆN

3.1. Sản phẩm đạt được


Hệ thống đã hình thành pipeline từ upload CSV đến Dashboard: đăng ký dataset version, lưu file theo phiên bản, profiling, semantic detection, recommendation/review/auto-bind, GX/Python validation, canonicalization, Scoring V2, Quality Gate và pipeline logs. CLI và Streamlit sử dụng cùng DqRuntime nên bảo đảm hành vi nhất quán.

3.2. Tính năng nổi bật và đóng góp


- Rule Catalog gồm 24 template mặc định, bao phủ sáu chiều chất lượng và các nhóm General, Business, Technical Rules.
- Profiling thu thập schema, null/blank, distinct, uniqueness, pattern, numeric summary và miscast evidence; hỗ trợ full scan, sampling và chunked profiling theo ngân sách.
- GX và Python evaluator có thể hoạt động trong cùng execution plan nhưng luôn trả về canonical measurement thống nhất cho Scoring Engine.
- Scoring Engine xử lý coverage theo final/provisional/insufficient_coverage, loại double-count bằng conflict group và cho phép hard gate chặn lỗi nghiêm trọng.
- Dashboard cung cấp năm khu vực Dashboard, Onboard, Catalog, System Health và Logs; hiển thị score, dimension, rule, recommendation, profiling evidence và issue sample đã masking ở lớp đọc.

3.3. Minh chứng thử nghiệm

Ảnh thử nghiệm:




Ảnh 3.1 Giao diện thêm mới dataset vào hệ thống



Ảnh 3.2 Cấu hình thông tin, metadata và các thuộc tính



Ảnh 3.3 Thông báo dataset đã được thêm thành công



Ảnh 3.4 Dataset mới được hiển thị trên Dashboard

Video thử nghiệm: [Đường dẫn youtube](#)

4. ĐÁNH GIÁ HIỆU QUẢ

4.1. Kết quả thử nghiệm

Tiêu chí	Kết quả
Quản lý dữ liệu	Quản lý dataset version, fingerprint, schema và storage path theo từng phiên bản.
Tự động hóa	Profiling, semantic detection, recommendation và safe auto-binding theo threshold.
Validation	Kết hợp Great Expectations/Python và chuẩn hóa thành canonical measurement.
Scoring	Sáu chiều chất lượng, severity, criticality, conflict, coverage và Quality Gate.
Khả năng giải thích	Truy vết Dataset Score xuống Dimension, Rule Score, Measurement và issue sample.
Vận hành	Dashboard và CLI dùng chung runtime; PostgreSQL lưu lịch sử và pipeline logs.
Kiểm thử	pytest gồm unit, PostgreSQL integration và fresh-install smoke trong GitHub Actions.

4.2. Điểm mới và sáng tạo

- Canonical measurement là hợp đồng trung tâm, giúp thay đổi validation backend mà không phải sửa công thức scoring.
- Recommendation sử dụng nhiều thành phần evidence và cơ chế review/auto-bind, thay cho việc cấu hình thủ công toàn bộ rule theo từng dataset.
- Scoring tách điểm số, coverage và Quality Gate; lỗi critical ở Business Key, CDE hoặc Mandatory field không bị che khuất bởi điểm trung bình cao.
- PostgreSQL kết hợp versioned CSV storage, migration, health check và pipeline log giúp kết quả có thể tái hiện và kiểm tra lại.

5. KẾT LUẬN

5.1. Kết quả chính

Đề tài đã xây dựng nền tảng DQ Scoring theo hướng tập trung và có thể giải thích. Hệ thống tự động khảo sát dữ liệu, gợi ý rule, thực thi validation, tính điểm theo sáu chiều và cung cấp Quality Gate cùng Dashboard theo dõi.

5.2. Tính mới, sáng tạo và hiệu quả

- Kỹ thuật: kết hợp Rule Catalog, recommendation, GX/Python validation và PostgreSQL trong một pipeline thống nhất.
- Thiết kế: canonical measurement và repository layer giảm phụ thuộc giữa giao diện, validation backend và scoring.
- Hiệu quả: severity, criticality, conflict, coverage và policy snapshot làm rõ nguyên nhân hình thành điểm số.

5.3. Khả năng ứng dụng và hướng phát triển

Hệ thống phù hợp cho demo, kiểm thử local và làm nền tảng đánh giá dataset trước khi chia sẻ hoặc công bố. Hướng phát triển gồm API service, scheduler/job queue, RBAC/audit, mở rộng nguồn dữ liệu ngoài CSV, governance workflow và tối ưu recommendation/validation cho dataset lớn; hiện sampling và chunking tập trung chủ yếu ở profiling.

6. TÀI LIỆU THAM KHẢO

1. Great Expectations, “Great Expectations Documentation,” <https://docs.greatexpectations.io>.
2. PostgreSQL Global Development Group, “PostgreSQL Documentation,” <https://www.postgresql.org/docs/>.
3. Psycopg Team, “Psycopg 3 Documentation,” <https://www.psycopg.org/psycopg3/docs/>.
4. pandas Development Team, “pandas Documentation,” <https://pandas.pydata.org/docs/>.
5. Streamlit, “Streamlit Documentation,” <https://docs.streamlit.io>.
6. Docker Inc., “Docker Compose Documentation,” <https://docs.docker.com/compose/>.